

관광 바이럴 조기경보 DB 사용 설명서

tour_earlywarning | 분석팀 배포본 | 데이터 동결 2026년 9월 22일

이 문서는 팀원이 MySQL 데이터를 안전하게 조회하고 시계열 예측과 이상탐지 분석을 바로 시작할 수 있도록 정리한 사용 안내서다. 분석의 기본 지역 단위는 228개 시군구 정보이며, 원본 테이블을 직접 조합하기보다 아래 권장 뷰를 우선 사용한다.

1 핵심 결론

- 수가 같은 지역 날짜 단위로 정리되어 있다.
- 지역 조인 키는 region_name이 아니라 region_id를 사용한다.
- 월별 데이터랩 자료는 일별 예측에 그대로 복제하지 않는다. 사후 설명 또는 공개 시차를 반영한 지연 변수로 사용한다.
- 뉴스 블로그 웹 근거는 사후 원인 설명용이다. 예측 시점 이후에 게시된 자료를 입력 변수로 사용하면 안 된다.
- 원본 적재와 수집은 동결됐다. 팀 계정은 SELECT와 SHOW VIEW 범위에서 분석한다.

2 접속 방법

항목	설정값
Host	103.218.161.72
Port	3306
Database	tour_earlywarning
SSL	REQUIRED
계정	팀원별 tour_team 계정
비밀번호	개별 전달 문서 및 저장소 업로드 금지

```
mysql -h 103.218.161.72 -P 3306 -u 사용자명 -p --ssl-mode=REQUIRED tour_earlywarning
```

Workbench에서는 SSL 탭의 Use SSL을 Require로 설정한다. 접속 후 아래 명령으로 암호화 연결을 확인한다.

```
SHOW STATUS LIKE 'Ssl_cipher';
```

3 데이터 구조

DB는 정보 지역, 핵심 시계열, 월별 보조지표, 사건과 외생변수, 이상탐지 결과의 다섯 층으로 구성된다.

층	대표 객체	용도
지역 정보	dim_region	228개 분석 지역과 행정구역 식별자
일별 핵심	fact_signal, vw_daily_core_signal	검색 관심과 방문 실현 신호
월별 보조	vw_datalab_canonical_monthly	SNS 체류 숙박 내비게이션 소비 설명
외생변수	analysis_calendar, event, event_point, raw_kma_asos_daily	휴일 축제 날씨
분석 결과	vw_final_anomaly_analysis	450개 이상 에피소드와 설명 요인

4 주요 테이블과 뷰

객체	주기와 범위	행과 지역	사용 판단
dim_region	정보 마스터	228개 지역	모든 지역 조인의 기준
fact_signal	일별 원천 통합	방문자 2018-01~2026-08, 네이버 2023-01~2026-08	긴 기간 개별 신호 조회
vw_daily_core_signal	일별 교집합 2023-01~2026-08	301,416행, 228지역, 1,322일	시계열 예측 권장 시작점
vw_datalab_canonical_monthly	월별 2020-01~2026-08	18,240행, 228지역, 80개월	월별 설명 및 보조 분석
datalab_detail_row	세부 원천 2020-01~2026-08	2,829,331행	원천 확인용, 직접 조인 주의
vw_datalab_detail_monthly_summary	월별 세부 정보	18,119행	동반유형 여행유형 목적지 소비업종
major_attraction_visitors_monthly	월별 2004-07~2026-06	847,656행, 관광지 4,159개	관광지 단위 쏠림 분석
raw_kma_asos_daily	일별 2023-01~2026-08	128,535행, 96관측소	날씨 외생변수
event 및 event_point	사건 단위 2023~2026	축제 2,562건, 점 5,124건	축제 시작 종료와 지역 연결

youtube_video	영상 단위	6,338건, 6지역	탐색적 보조자료만 사용
vw_final_anomaly_analysis	에피소드 단위 2023~2026	450건, 146지역	최종 탐지 결과와 원인 맥락

5 핵심 시계열 뷰

vw_daily_core_signal은 지역 날짜별 검색량과 방문자 수가 동시에 존재하는 분석용 일별 패널이다.

컬럼	의미
region_id	정본 지역 식별자
region_name	표시용 지역명
observed_date	관측일
day_of_week	요일
is_weekend	주말 여부
is_public_holiday	공휴일 여부
holiday_name	공휴일명
naver_interest	재정규화된 네이버 검색 관심지수
visitors_external	외지인 방문자 수
visitors_local	현지인 방문자 수
visitors_foreign	외국인 방문자 수
youtube_sample_videos	그날 표본 영상 수
youtube_sample_views	그날 표본 영상 조회수 합

네이버 값은 절대 검색건수가 아니라 배치와 구간을 연결해 재정규화한 상대 지수다. 수준 자체보다 동일 지역의 시간 변화와 급증을 해석한다.

```
SELECT region_id, region_name, observed_date,
       naver_interest, visitors_external,
       day_of_week, is_weekend, is_public_holiday
FROM vw_daily_core_signal
WHERE observed_date BETWEEN '2023-01-01' AND '2026-08-14'
ORDER BY region_id, observed_date;
```

6 시계열 모델 권장 설계

단계	입력	목적
기준선	방문자 lag 1 7 14 28일, 요일, 휴일	검색지수 없이 기본 예측력 측정
달력 날씨	기준선 + 축제 예정 + 기온 강수 바람	알려진 외생변수 통제
선행지표	이전 단계 + 네이버 lag 1 3 7일과 rolling 7일	검색 신호의 추가 기여 측정
이상탐지	실제 방문자와 예측값 또는 예측구간의 차이	기대 수준을 벗어난 지역 날짜 식별

평가는 반드시 시간 순으로 수행한다. 아래 구간은 현재 데이터에서 적용 가능한 단순 예시이며, 최종 모델은 expanding window 검증을 권장한다.

```
Train      2023-01-01 ~ 2024-12-31
Validation 2025-01-01 ~ 2025-12-31
Test       2026-01-01 ~ 2026-08-14
```

- 랜덤 train test split을 사용하지 않는다.
- 결측 대체, 표준화, 임계값 설정은 각 학습 구간만으로 계산한다.
- 지역별 모델 또는 region_id 효과를 포함한 전역 모델을 비교한다.
- MAE와 sMAPE를 기본 오차로 사용하고, 큰 지역이 지배하지 않도록 지역별 지표도 함께 보고한다.
- 네이버 추가 모델이 기준선보다 오차와 조기탐지 리드타임을 개선하는지 비교한다.

7 월별 데이터랩 사용법

vw_datalab_canonical_monthly는 행정개편 전후 원천 259개 명칭을 228개 정본 지역으로 통합한 월별 패널이다. canonical_region_id와 period_start가 한 행을 식별한다.

지표군	대표 컬럼	권장 사용
방문	visitors, visitors_yoy_pct, unique_visitors	월별 방문 규모와 전년 대비 변화
SNS	sns_mentions	월별 사후 설명, 일별 바이럴 발생일 판단 불가

체류 숙박	avg_nights, stay_minutes, overnight_visit_pct	방문의 질과 체류 형태
탐색	lodging_searches, navigation_searches	숙박 및 목적지 탐색 변화
소비	tourism_spend_outsider_krw_thousand 등	외지인 소비 변화
지역화폐	local_currency_spend_krw_thousand	2026년 8월 다수 결측으로 제한적 사용

월별 값을 같은 달의 모든 날짜에 복제하면 월말까지 알 수 없던 정보가 월초 예측에 들어갈 수 있다. 일별 모델에 넣을 때는 실제 공개 시점을 기준으로 전월 값만 사용하거나 월별 모델을 별도로 만든다.

8 사건 날씨와 증거 데이터

객체	상태	주의사항
event, event_point	문화축제 표준데이터 2,562건 적재	행사 기간과 지역 일치는 인과관계 확정이 아님
raw_tourapi_festival	0행	TourAPI 응답 문제로 비어 있음, 사용하지 않음
raw_kma_asos_daily	128,535행	96개 관측소를 지역에 매핑해서 사용
raw_kma_warning	0행	과거 특보 API 제약으로 비어 있음
event_evidence_candidate	15,590행, 220에피소드	뉴스 블로그 웹 검색 결과, 사후 설명용
special_calendar_day	공휴일 선거일 명절 등	예측 시점에 알려진 달력 변수로 사용 가능

9 최종 이상탐지 결과

vw_final_anomaly_analysis는 검색량과 외지인 방문자 급증으로 탐지된 450개 에피소드에 축제, 달력, 날씨, 외부 증거와 월별 데이터랩 맥락을 연결한 최종 뷰다.

분류	건수	해석
calendar_related	160	휴일 명절 등 달력 효과 우선
festival_exact_overlap	109	방문 피크 또는 에피소드가 축제 기간과 중첩
festival_pre_signal	26	검색 신호가 축제 시작 전에 발생
festival_nearby	12	축제 전후 인접 기간
weather_context	29	날씨 맥락이 우선 설명
external_evidence	22	강한 외부 근거
possible_external	23	가능성 있는 외부 근거
unexplained_candidate	69	추가 인간 검토 대상

74.0%는 정확도가 아니라 알려진 외부 요인과 보수적으로 연결된 비율이다. 전국 모든 실제 사건의 정답 집합이 없으므로 이 값으로 재현율이나 F1을 계산하지 않는다.

```

SELECT region_name, episode_start, episode_end,
       search_peak_date, visitor_peak_date,
       peak_anomaly_score, peak_naver_ratio, peak_visitor_ratio,
       final_explanation_group, representative_festival_name,
       weather_context_type, evidence_title
FROM vw_final_anomaly_analysis
ORDER BY peak_anomaly_score DESC
LIMIT 50;

```

10 키와 조인 규칙

자료	기본 키 또는 권장 조인 키
지역 정보	dim_region.region_id
일별 신호	region_id + observed_date
월별 데이터랩	canonical_region_id + period_start
이상 에피소드	region_id + episode_no
축제	event.event_id, 지역 연결은 event_point
ASOS	station_id + observed_date
관광지 월별	관광지 식별자 + period_start

- region_name은 출력과 확인에만 사용하며 조인 키로 사용하지 않는다.
- 일별과 월별 자료를 조인할 때 날짜를 월초로 변환하되 공개 시점 누출을 별도로 점검한다.
- 행정개편 전후 원천 지역은 정본 매핑 뷰를 사용한다. 원천 코드끼리 직접 결합하지 않는다.

11 데이터 품질과 제한

- YouTube 자료는 6개 지역 6,338건으로 전국 모델의 공통 입력으로 사용할 수 없다.
- 데이터랩 SNS 언급량은 월별이므로 일별 바이럴 발생일을 직접 식별하지 못한다.
- 네이버 검색지수는 상대지수이며 구간 연결 보정을 거쳤다. 절대 검색건수로 해석하지 않는다.
- 지역화페 소비는 2026년 8월 기준 228개 중 209개 지역이 결측이다.
- ASOS는 행정구역별 관측이 아니라 대표 관측소 매핑이다.
- 축제 매칭은 지역과 시간의 일치이며 원인의 확정은 기사 공식자료 등 인간 검토가 필요하다.
- 2026년 후반 값은 프로젝트 기준 시점보다 미래 날짜를 포함할 수 있으므로 공모전 데이터 기준일과 가상 기준시점을 명시한다.

12 시작 전 확인 SQL

```
USE tour_earlywarning;

SELECT COUNT(*) AS rows_actual,
       COUNT(DISTINCT region_id) AS regions,
       MIN(observed_date) AS date_min,
       MAX(observed_date) AS date_max
FROM vw_daily_core_signal;

SELECT final_explanation_group, COUNT(*) AS episodes
FROM vw_final_anomaly_analysis
GROUP BY final_explanation_group
ORDER BY episodes DESC;

DESCRIBE vw_daily_core_signal;
DESCRIBE vw_datalab_canonical_monthly;
DESCRIBE vw_final_anomaly_analysis;
```

13 팀 작업 권장 순서

순서	작업	산출물
1	vw_daily_core_signal 추출 및 날짜 지역 중복 점검	분석 패널
2	방문자 과거값과 달력만 사용한 기준선 모델	기준 MAE sMAPE
3	축제와 날씨 변수 추가	외생변수 개선폭
4	네이버 검색지수 시차 변수 추가	선행지표 개선폭
5	예측잔차 기반 이상 임계값 설정	지역 날짜 경보
6	450개 기준 에피소드 및 인간검토 라벨과 비교	적중 사례 오경보 사례
7	영월 주 사례와 거제 대비 사례 시각화	발표 그래프와 해석

문서 관리

데이터 기준일 2026년 9월 22일. 이후 테이블 또는 뷰가 변경되면 DESCRIBE와 기간 행 수 검증 결과를 갱신한다. 접속 비밀번호와 API 키는 문서 저장소에 포함하지 않는다.